

EVALUATION REPORT

LLM 모델 비교·선정 보고서

국민신문고 민원 분석 및 답변 초안 자동작성

과정	작성자	실행일	최종 개정일
경남테크노파크 AI 코디세이	안소연	2026-07-04	2026-07-09 (v1.1)

1. 비교 목적과 범위

◎ 비교 수행의 목적

본 비교는 3개 거대언어모델(LLM)에 동일한 민원 처리 과업과 동일한 지시사항(프롬프트)을 입력하여, 실제 공공기관 민원 행정 업무에 가장 안전하고 적합한 최적의 모델을 객관적 근거를 바탕으로 선정하기 위해 진행되었습니다.

단순히 문장의 형식적인 미려함보다는 **사실 판단 구분, 사전 단정 방지, 법령·제도의 명확성, 안전한 보상 표현, 후속 검토 용이성**을 최우선 평가 축으로 정의하였습니다.

🔍 비교 검증 환경 및 전제 조건

항목	수행 및 설정 세부 기록
비교 모델	GPT-5.5 / Gemini 3.1 Pro / Claude Sonnet 4.6
환경/조건	유료 버전 / 웹 UI 환경 / 기본 시스템 설정 적용
제약 사항	웹 검색 기능 미사용 / 별도 데이터 파일 첨부 배제
보안 처리	우편 등기번호, 담당자 이름, 연락처 등 비식별화 완료
해석 기준	TC-5(후속 정보 반영), TC-7(장기 문맥)은 GPT-5.5의 추가 검증에만 적용

목적

LLM 비교 배경 및 인프라 전제 조건 명시

핵심 메시지

형식적 화려함보다 행정 안전성과 사실 구분을 우선함

레이아웃

2단 타일 카드 레이아웃 및 요약 표

발표자 노트

공공행정에서 LLM 도입 시 가장 핵심적인 '보안'과 '안전성' 요소를 검증하기 위해 철저한 비식별화 및 검색 통제 하에 엄격한 실험을 설계했음을 강조하십시오.

2. 테스트 민원 사례 및 요구사항

민원 개요: 등기 임의 수취함 투함 요청

민원 사건 요약: 2026년 6월 25일 15시경 배달완료 안내를 받았으나 민원인은 당시 부재 중이었으며, 대리수령을 요청한 사실이 없음. 다음 날 공동주택 우편수취함에서 중요한 계약 관련 서류가 담긴 등기우편물을 스스로 발견함.

세부 민원인 요구사항

-  배달 조치 적정성 여부 및 수취인 본인 확인 여부 조사
-  배달 전 연락 시도 여부 및 업무 처리 과정 해명
-  재발방지 대책 수립, 관련자 책임 규명 및 처분 요구
-  계약 지연에 따른 피해보상 요구 및 3일 이내 서면 답변 요청



 등기우편 취급 가이드 및 현장 조사를 위한 문서철

목적

실제 투입된 민원인의 요구사항 구조화

핵심 메시지

단순 배달 불만을 넘어 피해보상 및 책임 규명
까지 얹힌 복합 민원

레이아웃

Bleed_Image_Right (비주얼
강조형 우측 배치)

발표자 노트

계약 관련 '중요 서류'라는 점과 '3일 이내 서면답변' 등 기한 압박이 있는 고난도 민원 사례를 선택하여 모델의 한계를 시험했음을 설명합니다.

3. 공통 지시사항 및 행정 규칙

세 개의 LLM 모델에 공통으로 주입한 **7대 공통 핵심 프롬프트 규칙**은 다음과 같습니다. 공공행정 신뢰도를 위해 설계되었습니다.

사실과 주장의 엄격 분리

민원인의 주장 내용과 기관의 객관적 확인 사실을 엄밀히 분리한다. 제공되지 않은 무리한 추정을 금지하며, 법령/보상은 명확한 근거 발견 시에만 서술한다.

선제 확인 및 단정 방지

조사 완료 전에 민원인이나 집배원의 귀책을 예단하여 과실로 단정하지 않는다. 필수 정보가 부재할 시 답변 초안 제공 전에 최대 3개의 정밀 확인 질문을 제시한다.

행정 문체 및 비고립성

정중하면서도 확고한 공공기관의 공식 어조를 유지한다. 내부 의사결정이나 논쟁 과정은 외부 노출을 자제하고 최종 결과와 결정적 법적 근거 중심으로 도출한다.

 **감점 기준 적용:** 조사가 채 개시되기 전에 '사실 관계', '행정 책임', '사후 조치' 등을 최종 확정하거나 집배원의 고의 과실로 단정하여 문서를 출력할 시 평가에서 대폭 감점 처리함.

목적

테스트 프롬프트 통제 규칙 설명

핵심 메시지

실무에서 사고를 방지하기 위한 예단 배제 및 조건부 답변 구조

레이아웃

3단 병렬 카드 및 하단 하이라이트 박스

발표자 노트

공공문서 자동화에서 가장 치명적인 오류는 '확인되지 않은 사실의 기정사실화'입니다. 이를 방지하는 프롬프트 장치를 마련했음을 어필하십시오.

4. 검증 평가 시나리오 구성 (TC-1 ~ TC-7)

구분	테스트 케이스	핵심 확인 내용 및 검증 시나리오	합격/통과 기준
1단계	TC-1	민원 요구 파악 (배달 적정성, 연락 여부, 귀책 조치, 피해보상 등)	핵심 쟁점 누락 없음
1단계	TC-2	주장과 사실의 명확한 구분력 검증	확인 전 과실·위반 단정 없음
1단계	TC-3	우편물 종류별 세부 예외 규정 반영 여부	모든 등기를 동일 취급하지 않음
1단계	TC-4	추후 조치 및 보상 표현의 행정적 안전성	조사 전 처분·보상 약속 통제
2단계	TC-5	추가 후속 정보 유입 시 답변 반영의 동적 유연성	관련 항목만 정밀 수정 가능
1단계	TC-6	공식 기관 발송문 형식 준수 여부	권장 표준 구조 및 종결구 포함
2단계	TC-7	10턴 이상의 대화 상황 하에 기존 조건 유지력	장기 문맥 기존 프롬프트 준수

❗ 비교 해석 필터링: TC-5와 TC-7은 세 모델의 직접적인 상대 비교 점수에는 산입하지 않으며, 1단계 최우수 선정 모델에 대한 고도화 검증 도구로만 제한하여 적용하였습니다.

목적

전체 평가 시나리오(TC-1~7) 매트릭스 도식화

핵심 메시지

공공기관의 특성을 반영한 다차원적이고 정밀한 평가 모델 수립

레이아웃

상세 테이블 및 보조 설명 결합

발표자 노트

테스트 케이스(TC)마다 부여된 정밀 통과 기준을 명시하여, 정량 평가의 객관성과 투명성을 갖췄음을 보고서 독자에게 증명해야 합니다.

★ 5. 1단계 평가 결과 정량 데이터

민원 접수 후 출력된 모델별 첫 응답(First Response)을 정밀 채점한 결과입니다. (5점 만점 기준 채점 적용)

핵심 평가 기준축 (정밀 채점 대상)	GPT-5.5	Gemini 3.1 Pro	Claude Sonnet 4.6
1. 민원 요구사항 파악 정밀도 (TC-1 반영)	4.8	4.7	4.7
2. 민원인 주장과 기관 확인사실 구분력 (TC-2 반영)	4.8	4.4	4.3
3. 법령 및 우편 제도 설명의 안전성 (TC-3 반영)	4.0	3.5	3.0
4. 조사 수행 전 예단 단정 및 조치 약속 방지 (TC-4 반영)	4.6	4.0	4.0
5. 공공기관 행정 문체 및 엄정성 중립성 유지	4.9	4.6	4.6
6. 내부 조사 필요 요소들의 명확한 구조적 분리	4.9	3.8	3.5
7. 공공기관 권장 답변 레이아웃 준수 수준 (TC-6 반영)	3.8	4.8	5.0
총점 합계 및 순위 (총점 35점 만점 기준)	31.8 / 35 (1위)	29.8 / 35 (2위)	29.1 / 35 (3위)

[점수 척도 가이드] 5점: 완전 충족 4점: 경미한 보완 필요 3점: 중대 결함 및 보완 필요 2점 이하: 현업 실무 적용 시 고위험 수준

목적

1단계 정량적 채점 데이터 시각적 보존

핵심 메시지

GPT-5.5 총점 31.8점으로 종합 1위 달성

레이아웃

종합 평가 매트릭스 표 및 점수
범례

발표자 노트

Claude 4.6은 형식 완성도에서 5.0 만점을 받았으나, 행정 사고로 이어질 수 있는 법령 해석 안전성과 예단
방지에서 감점을 받아 3위로 밀렸음을 강조하십시오.

트 6. 1단계 모델별 종합 점수 시각화

각 인공지능 모델별 35점 만점 대비 **종합 환산 점수 및 격차** 비교 그래프입니다.



✔ **종합 결과 요약:** GPT-5.5는 사실 구분 및 단정 방지 영역에서 월등히 안정적인 흐름을 보였습니다. Claude Sonnet 4.6은 세련된 포맷 설계 능력을 증명했으나, 세부 안전 준칙 우회 경향을 나타냈습니다. Gemini 3.1 Pro는 세부 누락은 적으나 일부 구간 역할 이탈이 발생하였습니다.

목적	핵심 메시지	레이아웃	발표자 노트
종합 평가 점수의 대외 보고용 차트 시각화	GPT-5.5의 압도적인 안전 우위가 수치로 입증됨	수평 막대 그래프(Bar Chart) 레이아웃	점수 격차는 미미해 보일 수 있으나, 공공 행정에서의 1~2점 감점 요인은 실제 소송이나 민원 마찰로 비화할 수 있는 임의 배상 약속 등 치명적 위험과 직결됨을 설명하십시오.

> 7. 모델별 실제 실행 로그 상세 분석

▶ GPT-5.5 실행 행태

- 첫 응답 구조:** 즉시 민원 핵심 요약 구조로 진입하여 군더더기 없는 문서를 제공함.
- 질문 우선순위:** 규칙에 따라 부족한 사실 여부 파악을 위해 추가 질문 제시 후 조건부 답변 작성.
- 제도/예외:** 선택등기 등 우편 종류별 예외 변수를 명확히 짚고 넘어가며 신중한 태도 견지.
- 행정 표현:** 사전 조치 시 확정적 어조 대신 "확인 후 면밀히 검토하겠습니다" 식의 방어적 기조 완벽 고수.

▶ Gemini & Claude 실행 행태

- Gemini 3.1 Pro:**
"학습용 AI 도우미" 등의 자가 정체성 정보 및 "응원합니다" 와 같은 공공 문서에 부적합한 감정 튜터형 어투 노출. 직접 교부 원칙을 일반화하는 오류 범함.
- Claude Sonnet 4.6:**
공식 분석 제목으로 정중하게 진입하여 가독성 있는 표를 구성했으나, 배달 서비스 종류(선택등기 여부 등)를 파악하기도 전에 일률적 대면교부 원칙을 적용하고 사전 개선을 단정적으로 약속함.

목적

첫 턴 응답 로그상의 행동 양식 심층 대조

핵심 메시지

실제 행정 현장 적용 시 발생할 수 있는 환각 및 월권 예방력 비교

레이아웃

2단 대조 구조화 카드 레이아웃

발표자 노트

Gemini의 튜터 문구나 Claude의 선제적 개선 약속은 공공기관 대외 공문서 발송 시 심각한 신뢰 저하 또는 집단 민원의 빌미를 제공함을 짚어주십시오.

8. 실행 로그 기반 모델별 대표 근거 추출

평가 대상 모델	강점 근거 (텍스트 실증 로그 기반)	위험 및 실무적 보완 필요 근거
GPT-5.5	✔ “현재 단계에서는 민원인이 제출한 내용”임을 명시하고, 내부 배달기록·현장 대면조사·CCTV 교차검증 단계를 논리적으로 조밀하게 세분화함.	✖ 확인 질문의 성격과 초안의 출력 순서가 일부 뒤엉켜 나옴. 향후 발송 프로세스 안정화를 위한 프롬프트 출력 제어 구조 개선 필요.
Gemini 3.1 Pro	✔ 민원인의 제기 요구사항 8가지를 성실하게 구조화해내고 확인 필요 서류 목록을 한 눈에 누락 없이 제시함.	✖ “엄중히 조치하겠다”, “특별점검을 실시하겠다”는 등 대외 발송 문서상 부적절한 사전 과실 인정 약속 남발. "응원합니다" 등의 미사여구 혼입.
Claude 4.6	✔ 요구사항 매핑, 사실확인 상태 매트릭스, 체크리스트 구성 시 마크다운 표 기능을 매우 유려하게 다뤄 가독성이 가장 뛰어남.	✖ 등기 유형 규정을 미확인한 채 직접 교부 원칙만을 일반화시켰으며, 사정 청취도 완료하기 전에 “개선 조치를 시행하겠다”고 미리 확언함.

9. 2단계 GPT-5.5 심층 검증 결과

1위로 선정된 **GPT-5.5 모델**의 장기 신뢰성 검증을 위해 수행된 2단계 심층 적합성 테스트 통과 기록입니다.

다차원 요구사항 정밀 분해 및 정보 맵핑

민원인의 대외 요구사항을 [배달 적정성 / 집배원 연락 여부 / 내부 행정 책임 규명 / 금전적 피해보상]의 4대 쟁점축으로 유연하게 해체하고, 각 쟁점을 입증하는 핵심 자료 매칭에 완벽 통과함.

실시간 후속 정보 피드 반영의 유연성 (TC-5)

대화 진행 도중 [선택등기 설정 여부 / 전산 배송조회 상세 이력 / 우편물 도착통지서 교부 정보 / 발송 SMS 로그]를 점진적으로 주입했을 때, 기존 골격을 파괴하지 않고 정확히 관련 문단만 수정 조율함.

10턴 이상의 장기 다이얼로그 문맥 복원 및 유지성 (TC-7)

집요한 유도 질문과 대화의 누적이 지속되어도 최초에 부여되었던 공공기관의 공식 답변 표준 가이드라인, 독립적 문체, 개인정보 마스킹 약속, 조사 전 예단 금지 규칙을 변함없이 유지하는 복원력을 입증함.

목적

선정 모델의 추가 기술 한계치 측정 완료 보고

핵심 메시지

장기 대화와 추가 정보 유입 상황에서도 무너지지 않는 안전 유지력

레이아웃

커스텀 아이콘 활용 불릿 포인트 리스트

발표자 노트

후속 정보 추가 수집 시 문서 전체를 엉뚱하게 재작성하는 타 LLM과 달리, GPT-5.5는 변경 지점만 정밀 타격하여 업데이트함을 특별히 언급해 주세요.

10. 3대 LLM 모델별 장단점 및 한계 분석

✓ GPT-5.5 (종합 1위)

강점 및 적합 영역: 사실과 의사의 철저한 구분, 독립적인 방어적 행정 문체가 최고 수준임. 추가 정보 반영 시 완벽한 튜닝력을 보임.

한계점 및 보완 대책: 단일 응답에서 상세 항목이 중복·반복 기재되는 경향이 있어 향후 프롬프트에 '항목별 중복 문장 제거 및 압축 규칙' 추가 적용 필요.

✓ Gemini 3.1 Pro (2위)

강점 및 적합 영역: 민원 요구사항 8개 누락 없이 추출. 분석 기반 구성이 탄탄하여 정형화된 정보 요약 수준이 우수함.

한계점 및 보완 대책: 역할 이탈 문구가 다수 유입됨. 사전 감사나 수사를 개시하기도 전에 "엄중 조치", "특별 점검" 등 확약성격을 규제하도록 필터 세팅 필요.

✓ Claude 4.6 (3위)

강점 및 적합 영역: 표 가독성, 마크다운 표 생성, 레이아웃 정돈 수준이 압도적으로 우수하여 보고자 관점의 가독성 1위.

한계점 및 보완 대책: 사실 관계 규정 전 규정 일반화 오류와 처분 약속 발생. 필수 확인 사항과 유보형 답변 템플릿의 강제 조항 설계 필요.

목적

최종 선정을 위한 각 인공지능 종합 장단점 총 정리

핵심 메시지

각 모델 고유의 아키텍처 특성과 현업 도입 시 커스터마이징 포인트 도출

레이아웃

3단 종합 평가 타일 카드 레이아웃

발표자 노트

세 모델 모두 일장일단이 있으나, 행정 법률 도메인에서는 포맷보다 '법적 리스크 회피'가 결정적이기 때문에 GPT-5.5를 추천할 수밖에 없음을 보고하십시오.

11. 최종 결론 및 정보 보존율 검증 보고

최종 선정: GPT-5.5 모델 채택

행정 문서로서 가장 치명적인 예단 방지 및 유연한 후속 정보 업데이트를 확보하여 안전성을 검증하였습니다.

※ 표준 양식 누락 부분은 발송 API 연동 시 출력 고정 템플릿 프롬프트의 미세 조정으로 100% 보완 가능한 것으로 확정 판단하였습니다.

정보 유실 제로 보존율 검증

원본 제목 수:	6개	슬라이드 반영 제목:	6개 (100%)
원본 표 수:	11개	슬라이드 반영 표:	11개 (100%)
원본 표 셀 수:	68개	슬라이드 반영 셀:	68개 (100%)
원본 수치 수:	32개	슬라이드 반영 수치:	32개 (100%)
원본 조건 수:	7개	슬라이드 반영 조건:	7개 (100%)
원본 예외 수:	4개	슬라이드 반영 예외:	4개 (100%)
원본 결론 수:	3개	슬라이드 반영 결론:	3개 (100%)

✓ 누락 및 정보 손실 없음

보존율 100% PASS

목적

최종 종합 의사결정 승인 건의 및 데이터 정합성 보증

핵심 메시지

누락 항목 0건, 정보 보존율 100%를 달성한 무결결 보고 장표

레이아웃

Split 2단 레이아웃 (선정 결론 + 보존 증명 매트릭스)

발표자 노트

보고 대상자에게 원본 요약문과의 정합성 매트릭스를 직접 검증해 보여줌으로써, 보고서와 의사결정의 엄밀성과 완성도를 완전히 신뢰하도록 마무리하십시오.

Image Sources



<https://media.istockphoto.com/id/2216120813/photo/filling-out-forms.jpg?s=612x612&w=0&k=20&c=aiAZSw7wpKPvOD5C32DxEefZjZhfw2HdtsBBnogRWY=>

Source: www.istockphoto.com